# 人工智能基础实验 2

傅申 PB20000051

# 1. 实验环境

本次实验的代码在我的笔记本上运行, 配置如下:

**CPU** Intel i5-1035G1

**GPU** NVIDIA GeForce MX350

内存 16 GB 双通道 DDR4

相应的软件环境如下, 其中 Python 环境及其相关包由 micromamba 包管理器提供:

操作系统 GNU/Linux 6.1.31-2-MANJARO x86\_64

Micromamba 1.4.7

**Python** 3.10.12

**NumPy** 1.24.2

Matplotlib 3.6.3

OpenCV (OpenCV-Python/cv2) 4.7.0

PyTorch 2.0.1, build py3.10\_cuda11.8\_cudnn8.7.0\_0

**tqdm** 4.65.0

## 2. 传统机器学习

### 2.1. 贝叶斯网络手写数字识别

### 2.1.1. 实验原理与实现

记输入 (取值为 1/0 的像素矩阵/向量) 为 X.

在本次实验中,给定一个数据样本 x,模型要计算样本对应数字的概率分布 P(Y|X=x),并取概率最大的数字作为输出 (预测的数字).

由 Bayes 定理, 上面的概率分布可以写为

$$P(Y|X = x) = \frac{P(Y)P(X = x \mid Y)}{P(X = x)}$$
(1)

由于我们只关心概率分布的相对大小 (只选择最大值作为输出), 因此分母 P(X=x) 并不会影响模型, 因此有

$$\operatorname{Predict}(\boldsymbol{x}) = \operatorname*{argmax}_{y} P(Y = y) P(\boldsymbol{X} = \boldsymbol{x} \mid Y = y) \tag{2}$$

这意味着,我们只需要知道数字的先验概率分布和像素的条件概率分布,就可以构建出相应的模型 (Bayesian 网络) 来识别手写数字.

给定数据集  $D = \left\{ \boldsymbol{x}_i, y_i \right\}_{i=1}^N$ ,其中  $\boldsymbol{x}_i$  是一个屏幕像素信息 (长度为 M 的 1/0 向量),  $y_i$  是对应的数字, 我们可以估计所需的概率分布, 具体来说, 有

$$\begin{split} P(Y=y) &= \frac{1}{N} \sum_{i=1}^{N} \mathbb{I} \Big( y_i = y \Big) \\ P(\boldsymbol{X} = \boldsymbol{x} \mid Y = y) &= \prod_{j=1}^{M} P \Big( \boldsymbol{X}_j = \boldsymbol{x}_j \mid Y = y \Big) \end{split} \tag{3}$$

其中

$$\mathbb{I}(x=y) = \begin{cases} 1 \text{ if } x = y \\ 0 \text{ otherwise} \end{cases}$$

$$P(\mathbf{X}_j = x \mid Y = y) = \frac{\sum_{i=1}^{N} \mathbb{I}(\mathbf{X}_j = x, y_i = y)}{\sum_{i=1}^{N} \mathbb{I}(y_i = y)}$$
(4)

综上所述,我们可以通过统计数据集中的信息,估计出所需的概率分布,并据此进行预测.其中,估计的过程可以通过以下代码实现:

这里的 labels\_prior[y] 对应上面的先验概率 P(Y=y), pixels\_cond\_label[j, x, y] 对应上面的条件概率  $P(X_i=x\mid Y=y)$ .

相应地, 预测的过程可以通过以下代码实现:

```
def predict(self, pixels):
    n_samples = len(pixels)
    labels = np.zeros(n_samples)
    pixels_cond_label_one = self.pixels_cond_label[:, 1, :]
    pixels_cond_label_zero = self.pixels_cond_label[:, 0, :]
    for i in range(n_samples):
        sample = np.transpose([pixels[i]])
        prob_one = np.multiply(sample, pixels_cond_label_one)
        prob_zero = np.multiply(1 - sample, pixels_cond_label_zero)
        prob = np.prod(prob_one + prob_zero, axis=0) * self.labels_prior labels[i] = np.argmax(prob)
```

考虑 for 循环中处理单个新样本 sample (记为 x) 的过程, pixels\_cond\_label\_one[j][y] 对应先验条件概率  $P(X_j=1\mid Y=y)$ , 而 pixels\_cond\_label\_zero[j][y] 对应先验条件概率  $P(X_j=0\mid Y=y)$ . 分别处理 x 中取值为 1 的部分 prob\_one 和取值为 0 的部分 prob\_zero, 将

其相加后得到 (prob\_one + prob\_zero)[j][y] 就对应先验条件概率  $P(\mathbf{X}_j = \mathbf{x}_j \mid Y = y)$ , 每列连乘就得到了  $P(\mathbf{X} = \mathbf{x} \mid Y)$ . 最后按照等式 2 计算预测结果.

### 2.1.2. 实验结果

运行程序,得到准确率为 0.843800,如下截图

```
O 1:.../lab-2/part_1/src

fushen in ai-fundamental/lab/lab-2/part_1/src on ₽ master [!?↑] via ♣ v3.11.3 took 39ms

> python Bayesian-network.py
test score: 0.843800

fushen in ai-fundamental/lab/lab-2/part_1/src on ₽ master [!?↑] via ♣ v3.11.3 took 1s

> □
```

图 1: Bayesian 网络运行结果

### 2.2. 利用 K-means 实现图片压缩

#### 2.2.1. 实验原理与实现

在本次实验中,输入为一张图片,模型将对图片上的像素点使用 K-means 算法进行聚类,并将所有数据点的值替换成其聚类中心的值,以达到压缩图片的目的.

具体而言, 我们将图片的每个像素点映射到 RGB 三维空间的数据点 (R,G,B), 对这些数据点进行聚类. 本次实验中定义数据点的距离为欧氏距离 (向量的 2-范数).

K-means 算法的伪代码如下:

对应的 Python 代码如下:

```
# k-means clustering
def fit(self, points):
    centers = self.initialize_centers(points)
    last_centers = centers.copy()
    for _ in range(self.max_iter):
        labels = self.assign_points(centers, points)
        centers = self.update_centers(centers, labels, points)
        diff = centers - last_centers
        if np.all(diff < 1e-5):
            break
        last_centers = centers.copy()
    return centers</pre>
```

### 其中

```
# Assign each point to the closest center
def assign_points(self, centers, points):
    n_samples, n_dims = points.shape
    labels = np.zeros(n_samples)
    dists = np.zeros((self.k, n_samples))
    for k in range(self.k):
        dists[k] = np.linalg.norm(points - centers[k], axis=1)
    labels = dists.argmin(axis=0)
    return labels

# Update the centers based on the new assignment of points
def update_centers(self, centers, labels, points):
    for k in range(self.k):
        centers[k] = points[labels == k].mean(axis=0)

    return centers
```

### 2.2.2. 实验结果

设定 k 分别为 2, 4, 8, 16, 32, 压缩后的图片如下所示:







a) 原始图片

b) k = 2

c) k = 4







e) k = 16图 2: 压缩后的图片



f) k = 32

# 3. 深度学习

### 3.1. 实验实现

基于提供的实验框架, 我对其中的代码进行了部分修改:

- (1) 直接实现 MultiHeadAttention 类, 而不是先实现 Head 再利用其实现 MultiHeadAttention.
- (2) 修改了 get\_batch() 函数的实现以使其更高效;
- (3) 使用 tqdm 库显示训练进度.

下面将针对前两点进行说明.

#### 3.1.1. MultiHeadAttention

MultiHeadAttention 类的实现如下:

```
class MultiHeadAttention(nn.Module):
    """multi-head self-attention"""
    def __init__(self, n_embd, n_heads):
        super().__init__()
        # parameters
        if (n_{embd} \% n_{heads} \neq 0):
            raise ValueError("n_embd must be divisible by n_heads")
        self.n_heads = n_heads
        self.d_k = n_embd // n_heads
        self.qkv_proj = nn.Linear(n_embd, 3 * n_embd)
        self.out_proj = nn.Linear(n_embd, n_embd)
        # mask for attention
        self.register_buffer("tril",
                             torch.tril(torch.ones(block_size, block_size)))
    def forward(self, inputs):
        batch, time, _ = inputs.shape
        qkv = self.qkv_proj(inputs)
        qkv = qkv.reshape(batch, time, self.n_heads, -1)
        qkv = qkv.permute(0, 2, 1, 3)
        q, k, v = qkv.chunk(3, dim=-1)
        out = q @ k.transpose(-2, -1) / math.sqrt(self.d_k)
        out = torch.masked_fill(out,
                                self.tril[:time, :time] = 0,
                                float("-inf"))
        out = F.softmax(out, dim=-1) @ v
        out = out.permute(0, 2, 1, 3).reshape(batch, time, -1)
        out = self.out_proj(out)
        return out
```

在实现中,我使用了一个线性层  $qkv_proj$  来一次性计算所有的 Q, K, V,并以此来直接计算 concat 后的 out (即 out\_proj 的输入).

#### 3.1.2. get\_batch()

如下代码是修改前后的代码对比:

```
# separate the dataset into train and validation
train_data = torch.tensor(encode(text[: -len(text) // 10]), dtype=torch.long)
val_data = torch.tensor(encode(text[-len(text) // 10 :]), dtype=torch.long)

def get_batch(split):
    data = train_data if split = "train" else val_data
    ix = torch.randint(len(data) - block_size, (batch_size,))
    x = torch.stack([data[i : i + block_size] for i in ix])
    y = torch.stack([data[i + 1 : i + block_size + 1] for i in ix])
    x, y = x.to(device), y.to(device)
    return x, y
```

```
# separate the dataset into train and validation
data = torch.tensor(encode(text), dtype=torch.long)
data_len = data.shape[0]
train_data = data[:-data_len // 10]
val_data = data[-data_len // 10:]
# Unfold into blocks
train_blocks = train_data.unfold(0, block_size, 1)
train_x = train_blocks[:-1]
train_y = train_blocks[1:]
val_blocks = val_data.unfold(0, block_size, 1)
val_x = val_blocks[:-1]
val_y = val_blocks[1:]
def get_batch(split: str):
    "Get batched data"
    if split = "train":
        x = train_x
        y = train_y
    elif split = "val":
        x = val_x
        y = val_y
    else:
        raise ValueError("split must be either 'train' or 'val'")
    idx = torch.randint(x.shape[0], (batch_size,))
    return x[idx].to(device), y[idx].to(device)
```

经过测试, 两个实现是等价的, 并且后者的速度会更快.

#### 3.1.3. Transformer 生成文本

在 Transformer.generate() 中,每轮迭代生成一个字符 (token) 添加到 inputs 末尾,重复 max\_new\_tokens 次迭代. 其中每次生成都只会取 inputs 末尾的至多 block\_size 个字符作为输入.

```
class Transformer(nn.Module):
    def generate(self, inputs, max_new_tokens):
        for _ in range(max_new_tokens):
            logits, _ = self.forward(inputs[:, -block_size:])
            probs = self.softmax(logits)
            next_token = torch.multinomial(probs[:, -1], num_samples=1)
            inputs = torch.cat([inputs, next_token], dim=1)
        return inputs

def generate(model, text = ""):
    if text = "":
        context = torch.zeros((1, 1), dtype=torch.long, device=device)
    else:
        context = torch.tensor([encode(text)], dtype=torch.long, device=device)
    print(decode(model.generate(context, max_new_tokens=500)[0].tolist()))
```

### 3.2. 实验结果

训练过程中的 Loss 变化如下图所示:

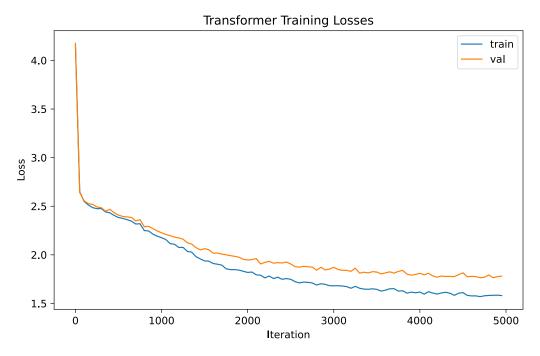


图 3: Transformer 训练过程中的 Loss 变化

generate() 输入的文本为 The meaning of life is, 模型输出如下截图所示:

```
The meaning of life is naturea.
Ah, sir, for to clie onjure's daly dison; if singly.
Puty:
You home, for trans of dather's nothies fried.'
PETERO:
Welcome pertaly enop, who, I know have your lilo,
We should's being adm by boke lulinge
With with up to all refiencer touchf,
Privatul, Loyard'd joy? 'C, I
HORSTABRLENG:
Nighter her, who sir, the his parporm twasan?
A woull, cretttation, thou hand slain a shine adks; I canno,
I have purposer o' a Oufier again,
Teache stin?
ESCALUS:
Oncest shall doubth them ime a Vol!
S
```

可以看到, 预测的字符能够组成类似英语单词的结构, 可以认为模型是学习到了一定的效果.

# 4. 总结与意见

在本次实验中, 我实现了两个传统机器学习算法 Bayesian 网络和 K-means 聚类, 并且实现了 Transformer 的 Decoder 模块.

意见: 希望设计 Transformer 实验的助教能注意一下自己的编码习惯 (不论是为了以后设计实验还是其他目的), 因为给出的实验框架中存在代码风格不一致的问题, 比如

- (1) class char\_tokenizer 和 class MultiHeadAttention 的命名风格不一致.
- (2) class char\_tokenizer 中的函数参数中有 Type Annotation, 其他函数均没有.