数据隐私实验二

傅申 PB20000051

目录

1.	代码实现方法	. 1
	Q1. 补全 ŷ 计算流程	
	Q2. 补全梯度计算流程	
	Q3. 补全训练过程中模型准确率计算流程	
	实验结果	
	文字描述说明	

1. 代码实现方法

Q1. 补全 \hat{y} 计算流程

这一部分对应于论文中算法的 Step 2 和 Step 3.

对于 Active Party A, 它首先计算 $\Theta^A x_i^A$, 并接收来自 Passive Party B 的 $\Theta^B x_i^B$. 然后二者相加得到 Θx_i , 再根据 Activation Function 计算 $\hat{y}_i = h_{\Theta}(x_i)$. 代码实现如下:

对于 Passive Party B, 它只需要计算 $\Theta^B x_i^B$, 并发送给 Active Party A 即可, 代码实现如下:

Q2. 补全梯度计算流程

这一部分对应于论文中算法的 Step 3, Step 4 和 Step 5.

首先, Active Party A 计算 \hat{y} 和 y 之间的误差 $(y_i - \hat{y}_i)$, 并将误差加密后得到 $[(y_i - \hat{y}_i)]$. 然后 A 将加密后的误差发送给 Passive Party B, 代码实现如下:

数据隐私实验二 傅申 PB20000051

然后, Passive Party B 接收加密后的误差, 并由此计算 Θ^B 的 (加密后的) 梯度 $\left[\left|\frac{\partial L}{\partial \Theta^B}\right|\right]$. 然后, B 生成随机掩码 (Mask) R_B , 并在加密后的梯度上加上加密后的随机掩码, 再将结果 $\left[\left|\frac{\partial L}{\partial \Theta^B}\right|\right] + \left[\left|R_B\right|\right] = \left[\left|\frac{\partial L}{\partial \Theta^B} + R_B\right|\right]$ 发送给 Active Party A. 代码实现如下:

```
passive.py line 100 ~ 105

100 # Q2. Receive encrypted residue and calculate masked encrypted gradients
101 # -----
102 enc_residue = self.messenger.recv()
103 enc_grad = self._gradient(enc_residue, batch_idxes)
104 enc_mask_grad, mask = self._mask_grad(enc_grad)
105 self.messenger.send(enc_mask_grad)
```

其中, mask grad()的实现如下:

```
passive.py line 45 ~ 49 (LinearPassive._mask_grad)

45    def _mask_grad(self, enc_grad):
46         mask = np.random.normal(0, 1.0, enc_grad.shape)
47         enc_mask = self.cryptosystem.encrypt_vector(mask)
48         enc_mask_grad = enc_grad + enc_mask
49         return enc_mask_grad, mask
```

Active Party A 在接收加密后的梯度后, 将其解密并发送回 Passive Party B. 代码实现如下:

最后, Passive Party *B* 接收解密后的梯度, 并去除其中的掩码, 得到解密后的梯度, 由此进行梯度下降. 代码实现如下:

```
passive.py line 106 ~ 111

106  # Receive decrypted masked gradient and update model
107  mask_grad = self.messenger.recv()
108  true_grad = self._unmask_grad(mask_grad, mask)
109  #
110
111  self._gradient_descent(self.params, true_grad)
```

数据隐私实验二 傅申 PB20000051

在上述过程中, Active Party A 同时 (在代码中表现为发送解密后的梯度后) 计算自己的梯度 $\frac{\partial L}{\partial \Theta^A}$, 并进行梯度下降. 代码实现如下:

```
active.py line 110 ~ 112

110 # Active party calculates its own gradient and update model
111 active_grad = self._gradient(residue, batch_idxes)
112 self._gradient_descent(self.params, active_grad)
```

Q3. 补全训练过程中模型准确率计算流程

这一部分需要补全 active.py 中的 LinearActive._acc() 函数. 代码实现如下:

```
active.py line 144 ~ 151 (LinearActive._acc)

144   def _acc(self, y_true, y_hat):
145      # Q3. Compute accuracy
146      #

147      y_pred = np.where(y_hat >= 0.5, 1, 0)
148      acc = np.sum(y_true == y_pred) / len(y_true)
149      #
150
151      return acc
```

2. 实验结果

先后运行 play_active.py, 即可开始训练纵向联邦逻辑回归模型. 运行效果如图 1 所示. 从截图中可以看出, 对于最后一个 batch, 模型的 loss 为 0.0844, 准确率为 100%.

记录训练过程每个 epoch 的模型的 loss 和准确率, 并绘制对应的曲线, 如图 2 所示. 从曲线中可以看出, 模型达到了较低的 loss 和较高的准确率, 可以认为模型已经收敛. 因此, 可以认为模型的训练是成功的.

3. 文字描述说明

· 请说明代码中 scale() 函数的原理及作用

原理 scale() 函数通过使用 sklearn 库中的 preprocessing.scale() 函数将数据集中每个特征的值进行标准化,使得每个特征的数据都近似于标准正态分布.

图 1 训练过程截图

数据隐私实验二 傅申 PB20000051

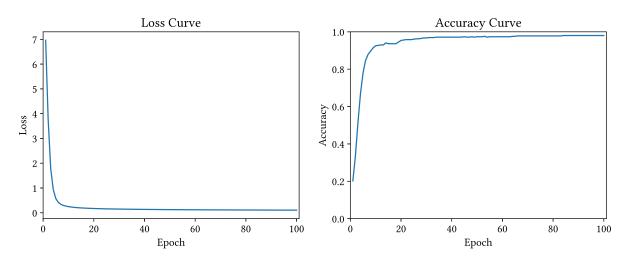


图 2 训练过程中的模型性能, 左图为 loss 曲线, 右图为准确率曲线

- **作用** 这样做可以避免规模较大的特征主导模型参数,有助于平衡各个特征对模型参数的影响,并提升模型的性能.
- 当前代码在每个 epoch 开始时使用 epoch 值作为随机数种子, 请说明含义, 并实现另一种方式 以达到相同的目的
 - **含义** 不断使用动态的随机数种子 (epoch 值) 重设 (伪) 随机数生成器, 可以避免 Active Party 通过分析随机掩码 (Mask) 的模式而推断出 Passive Party 的模型参数. 这种方式可以进一步保证隐私性.
 - **另一种实现** 可以使用其他动态参数作为随机数种子. 例如基于当前时间 t 计算出 f(t) 作为随机数种子, 其中 f 对 Active Party 是不可见的.
- 试分析 VFL-LR 训练流程中潜在的隐私泄露风险,并简要说明可能的保护方式
 - **风险** 如果 Active Party 是恶意的, 它可以在 Step 3 中设置误差为只含一个 1, 其余位置均为 0 的向量, 加密后发送给 Passive Party, 导致 Passive Party 在 Step 4/5 中计算得到的梯度中直接包含了模型的部分参数, 并被 Active Party 获取, 造成隐私泄露.
 - 可能的保护方式 Passive Party 可以增加随机掩码 (Mask) 的规模, 并在训练过程中随机重排特征和参数的顺序 (二者重排顺序相同, 不影响 $\Theta^B x^B$ 的值), 从而增加 Active Party 推断模型参数的难度, 保护隐私.